LAPORAN PRAKTIKUM 2 BIG DATA

Pengumpulan dan Prapemrosesan Data (Data Acquisition & Preprocessing)



Disusun Oleh:

Stanley Leonard Darmali/Kelas B

2311532021

Dosen Pengampu:

Afdhal Dinilhak

Ajeng Dwi Asti

Departemen Informatika

Fakultas Teknologi Informasi

Universitas Andalas

2026

Repository Github:
https://github.com/AbyssWatcher07/BigData26_B_2311532021_StanleyLeonardDarmali

Sumber Data & Etika Penggunaan Dataset

• Jenis Dataset: Sintetis (Synthetic Dataset) disimulasikan menggunakan pustaka Faker id_ID dan NumPy

• Tujuan Simulasi: Merepresentasikan transaksi mentah platform marketplace dengan variasi kotor yang terkendali

• Random Seed: SEED = 42 (Menjamin sifat deterministik dan reproduksibilitas hasil secara pasti)

• Jumlah Baris Mentah: 515 baris data transaksi (500 baris acak + 15 baris duplikat terpisah)

• Jumlah Baris Bersih: 490 baris data transaksi valid (setelah pembersihan missing values wajib dan duplikat)

• Pernyataan Integritas Data: Dataset ini murni buatan (sintetis) untuk kebutuhan simulasi pra-pemrosesan data transaksional pada Praktikum 02, bukan berasal dari transaksi nyata marketplace otentik.

1. Langkah-langkah Kerja (K-1 s.d. K-6)

• K-1. Import Library dan Inisialisasi: Menyiapkan seluruh pustaka utama yang digunakan, mencakup NumPy, pandas, Faker, dan random untuk pembangkitan data sintetis serta manipulasi tabular.

• K-2. Membuat Dataset Sintetis (Simulasi Data Acquisition): Mengunci generator acak dengan SEED = 42 dan membangkitkan 515 baris data transaksi mentah yang disuntikkan variasi format harga (teks/Rp/desimal), tanggal (ISO/non-ISO), kapitalisasi, missing values acak, serta 15 baris duplikat.

• K-3. Deteksi dan Penanganan Missing Value: Mendeteksi missing value per kolom. Mengeliminasi baris kotor pada kolom wajib customer_name (20 baris) dan payment_method (16 baris) via dropna(), mengimputasi shipping_city yang kosong (30 baris) dengan 'Tidak Diketahui', serta membiarkan rating (166 baris kosong) tetap NaN.

• K-4. Deteksi dan Penanganan Duplicate: Mendeteksi 15 baris duplikat sempurna (semua kolom identik) dan menghapusnya menggunakan drop_duplicates(), menyisa dari 515 ke 500 baris data.

• K-5. Koreksi Tipe Data dan Standardisasi Format: Menyeragamkan teks kategorikal ke Title Case (serta membetulkan singkatan 'COD'), membersihkan string harga menjadi float64, memparsing tanggal tercampur ke format ISO YYYY-MM-DD secara eksplisit tanpa format='mixed', dan mengeset tipe data quantity (int) serta price (float).

• K-6. Ekspor Dataset Bersih: Mengekspor 490 baris DataFrame yang telah dibersihkan sepenuhnya ke dalam file transaksi_bersih.csv sebagai deliverable utama praktikum.

2. Analisis Hasil (O)

Pengurangan Baris Data Mentah

Dari total 515 baris data mentah, sebanyak 25 baris (sekitar 4,9%) dibuang selama pra-pemrosesan: 15 baris karena duplikat sempurna dan 10 baris karena kehilangan data wajib (customer_name atau payment_method). Kehilangan data ini adalah hal yang wajar dalam data cleaning untuk menjamin keabsahan analisis.

Penanganan Kolom Rating

Kolom rating sengaja dibiarkan memiliki missing value (tanpa diimputasi) karena rating bersifat opsional dari pembeli. Mengisi rating kosong dengan nilai tebakan akan mendistorsi persepsi kepuasan pelanggan, sedangkan fungsi analisis statistik deskriptif pandas akan otomatis mengabaikan NaN secara objektif.

3. Studi Kasus (P.1 s.d. P.3)

• Penyebab Perbedaan Jumlah Baris (515 vs 490): Perbedaan 25 baris antara Laporan IT (515 mentah) dan Laporan Finance (490 bersih) disebabkan oleh eliminasi 15 transaksi duplikat jaringan serta pembuangan 10 transaksi kotor yang kehilangan entitas wajib pembeli/pembayaran (15 + 10 = 25 baris dibuang).

• Keabsahan 490 Baris Berdasarkan Konsep Veracity: Angka 490 baris jauh lebih valid dibanding 515 baris ditinjau dari dimensi Veracity. Menyajikan 515 baris akan menghasilkan pencatatan keuangan fiktif akibat overstatement 15 duplikat dan 10 data anonym tanpa identitas pembayaran.

• Penjelasan Kolom Rating kepada Tim Finance: Membiarkan rating kosong mencegah manipulasi buatan terhadap kepuasan pelanggan. Fungsi agregasi rata-rata (mean) secara otomatis hanya menghitung transaksi yang benar-benar diulas oleh pembeli tanpa membiaskan hasil.

4. Hasil Latihan Mandiri (Q.1 s.d. Q.3)

Q.1 Pengujian Pipeline dengan SEED = 7

Menjalankan pipeline dengan SEED = 7 menghasilkan 515 baris mentah dan 487 baris bersih. Jumlah baris mentah tetap 515 karena proporsi duplikat diset konstan (500 + 15). Namun, jumlah baris bersih berbeda (487 vs 490) karena variasi distribusi acak missing values pada kolom wajib (customer_name dan payment_method) yang tumpang tindih.

Q.2 Validasi Kolom Harga (is_valid_price)

Pemeriksaan menggunakan ekspresi logika df['price'] > 0 menghasilkan 0 harga tidak valid (semua bernilai True). Hal ini mengonfirmasi bahwa seluruh nilai harga hasil pembersihan berhasil dikonversi menjadi numerik positif tanpa adanya angka negatif atau NaN.

Q.3 Ringkasan Transaksi per Kategori Produk

Hasil eksekusi value_counts() pada kolom category menunjukkan distribusi transaksi bersih per kategori produk sebagai berikut:

Kategori Produk	Jumlah Transaksi Bersih
Elektronik	89
Fashion	85
Buku	84
Rumah Tangga	80
Kesehatan	78
Olahraga	74

5. Pertanyaan Evaluasi (S.1 s.d. S.5)

S.1 Perbedaan dropna() dan fillna() serta Waktu Penggunaannya

dropna() menghapus baris yang memiliki missing value, digunakan untuk kolom informasi transaksi wajib (seperti customer_name). fillna() mengisi missing value dengan nilai pengganti, digunakan untuk kolom pelengkap (seperti mengisi shipping_city dengan 'Tidak Diketahui').

S.2 Alasan drop_duplicates() Dijalankan di Awal Pipeline

Menjalankan drop_duplicates() di awal mencegah overhead komputasi pembersihan pada baris yang nantinya dibuang, serta menghindari risiko dua baris berbeda terubah menjadi identik secara tak sengaja pasca-transformasi.

S.3 Risiko Perintah pd.to_datetime dengan format='mixed' dan dayfirst=True

Kombinasi tersebut berbahaya pada campuran format ISO dan non-ISO karena dayfirst=True akan ikut membalik string tanggal ISO yang sebenarnya tidak ambigu (misalnya 2026-07-11 bisa salah terbaca menjadi 2026-11-07).

S.4 Alasan Kolom rating Dibiarkan Kosong dibanding shipping_city

Rating bersifat opsional sehingga diimputasi angka tebakan akan membiaskan tingkat kepuasan pelanggan asli. Sebaliknya, shipping_city diisi 'Tidak Diketahui' agar baris tetap dapat dihitung pada agregasi volume penjualan logistik.

S.5 Keterkaitan Praktikum dengan Dimensi Veracity pada 5V

Praktikum ini berfokus langsung pada Veracity (keandalan data) dengan menyaring noise, duplikat, dan missing value dari data mentah agar dataset memiliki derajat kepercayaan tinggi sebelum disimpan atau dianalisis.