LAPORAN PRAKTIKUM 3 BIG DATA

Pengumpulan dan Pra-pemrosesan Data untuk Big Data



Disusun Oleh:

Stanley Leonard Darmali/Kelas B

2311532021

Dosen Pengampu:

Afdhal Dinilhak

Ajeng Dwi Asti

Departemen Informatika

Fakultas Teknologi Informasi

Universitas Andalas

2026

Repository Github:
https://github.com/AbyssWatcher07/BigData26_B_2311532021_StanleyLeonardDarmali

1. Langkah-langkah Kerja (K-1 s.d. K-11)

• K-1. Menyiapkan Lingkungan: Mengimpor pustaka utama, menyambungkan Google Drive, dan menginisialisasi fungsi utilitas (ukur dan lineage) untuk melacak performa memori, waktu, serta asal-usul data.

• K-2. Akuisisi 1 (Unduhan Berkala): Mengunduh file Parquet transaksi dan CSV Zona dengan mekanisme penulisan atomik (.part lalu replace) dan exponential backoff untuk menanggulangi file korup saat koneksi terputus.

• K-3. Akuisisi 2 (API JSON): Mengambil data cuaca per jam dari Open-Meteo secara aman. Respons divalidasi dan rate-limit API dihormati menggunakan retry berjeda pada kode HTTP 429 atau 5xx.

• K-4. Akuisisi Cadangan (Sintetis): Merupakan fungsi cadangan (fallback) pembangkit cuaca acak berbasis distribusi Gamma dan Normal yang disiapkan jika API Open-Meteo diblokir. Tidak dieksekusi karena K-3 berhasil.

• K-5. Akuisisi 3 (Basis Data): Membaca tabel tarif dan transaksi dari database SQLite lokal (operasional.db) secara bertahap menggunakan parameter chunksize (50.000) untuk menghindari error Out of Memory (OOM).

• K-6. Profiling Kualitas Data: Membangun profil dan mengukur data pada enam dimensi kualitas (seperti kelengkapan penumpang, rentang jarak logis, dll.) untuk melihat persentase baris data yang kotor/gagal.

• K-7. Nilai Hilang dan Duplikat: Mengimputasi 'passenger_count' menggunakan nilai median per kelompok jam. Baris ganda dihapus menggunakan subset kolom transaksi unik (waktu, lokasi, harga) untuk mencegah penghapusan data sah.

• K-8. Outlier dan Join Tabel: Membatasi jarak menggunakan winsorizing pada P99.5 dan hanya menandai (bukan membuang) tarif ekstrem. Kemudian melakukan 3 operasi Left Join (Zona, Pembayaran, Cuaca) yang dijaga ketat oleh parameter validate='many_to_one'.

• K-9. Rekayasa Fitur & Scaling: Melakukan One-Hot Encoding dan standardisasi (StandardScaler) yang HANYA di-fit pada data latih lalu ditransformasikan ke data uji guna mencegah data leakage.

• K-10. Pipeline Idempoten & Partisi: Menyatukan logika K-2 hingga K-8 ke dalam satu fungsi terpadu. Data akhir diekspor sebagai file Parquet berpartisi berdasarkan kolom 'borough_naik' untuk optimasi query di masa mendatang.

• K-11. Pemrosesan PySpark: Mereplikasi logika pembersihan ke environment PySpark terdistribusi. Tabel zona yang kecil dikirim secara paksa menggunakan F.broadcast() agar join bisa berjalan cepat tanpa tahap shuffle memori yang mahal.

2. Analisis Hasil (O.1 s.d. O.7)

O.1 Peta Kualitas

Tiga aturan dengan tingkat kegagalan tertinggi pada dataset transaksi Januari 2023 adalah:

• Kelengkapan (passenger_count ada): Gagal pada 2,339% data (71.743 baris). Penyebab utamanya adalah galat perekaman dari sistem argo taksi atau perjalanan yang dipesan melalui aplikasi pihak ketiga yang tidak mewajibkan input jumlah penumpang.

• Validitas (jarak 0-100 mil): Gagal pada 1,498% data (45.950 baris). Penyebabnya adalah asusmi bisnis: nilai jarak ≤ 0 mengindikasikan perjalanan fiktif/dibatalkan setelah argo menyala, atau kerusakan GPS, sehingga data ini tidak valid untuk dianalisis.

• Konsistensi (durasi 1-180 menit): Gagal pada 1,186% data (36.383 baris). Sebagian besar merupakan perjalanan dengan durasi negatif (error waktu sistem) atau durasi sangat panjang (supir lupa mematikan argo di akhir shift).

O.2 Dampak Strategi Pengisian

Strategi 'isi_median' dan 'isi_modus' menurunkan simpangan baku (std) dari 0,8961 menjadi 0,8873. Pengisian menggunakan satu nilai konstan pada puluhan ribu *missing values* secara matematis akan memusatkan data secara artifisial di sekitar nilai konstanta tersebut. Penumpukan nilai di bagian tengah ini selalu menyebabkan varians dan simpangan baku menyusut (mengecil) secara paksa, sehingga tidak mencerminkan ragam data yang sebenarnya.

O.3 IQR vs Z-score

Pada kolom total_amount, metode IQR menandai 371.616 baris sebagai outlier, sedangkan metode Z-score hanya mendeteksi 87.248 baris—terdapat selisih 284.368 baris. Untuk distribusi tarif yang sangat miring ke kanan (right-skewed), metode IQR jauh lebih tangguh karena berbasis kuartil, sedangkan Z-score (yang berasumsi distribusi normal) sangat lambat merespons outlier akibat mean dan std yang sudah terlanjur tertarik oleh nilai-nilai ekstrem.

O.4 Biaya Komputasi & O.7 Pandas vs Spark

Pipeline Pandas penuh (7,55 detik) lebih cepat dibandingkan PySpark (15,51 detik) untuk data tunggal bulanan. Proporsi waktu komputasi terbesar pada Pandas habis untuk mengeksekusi penggabungan (join) terhadap string LocationID. Pada Spark, overhead manajemen eksekutor JVM membuatnya lebih lambat, namun efisiensi join terjaga dengan baik berkat pemanggilan 'BroadcastHashJoin'. Penulisan hasil akhir ke Parquet berpartisi memakan waktu terpisah 4,91 detik.

O.5 Cakupan Penggabungan

Terdapat 37.609 baris yang tidak memperoleh pasangan zona (Borough Unknown) dan 37 baris tanpa data cuaca. Baris tanpa zona ini biasanya berasal dari perjalanan rute luar kota atau error sistem pencatat lokasi N/A. Hal ini berarti analisis kewilayahan akan kehilangan akurasi spasial sebesar ±1,2% (margin of error).

O.6 Susut Data Kumulatif

Dari total 3.066.765 baris awal, tersisa 2.986.910 baris di akhir pipeline. Persentase baris yang terbuang adalah 2,60% (< 10%). Susut ini wajar dan dibenarkan karena baris yang dibuang didominasi oleh data rusak/fiktif, sementara outlier valid hanya ditandai, bukan dieliminasi.

3. Studi Kasus (Tim Pricing)

Hasil ekstraksi 'tabel_analitik' menunjukkan bahwa cuaca hujan (1) tidak memicu kenaikan tarif rata-rata secara universal di semua wilayah. Pada Manhattan dan Brooklyn, tarif median memang naik moderat saat hujan (misal Manhattan: $10.50 → $11.42). Namun, di wilayah lain seperti Queens, harganya nyaris statis.

Batasan Penggunaan Tabel (Disclaimer):

1. Agregasi menggunakan *median* bukan *mean*, sehingga aman dari lonjakan angka ekstrem (outlier), tapi kurang sensitif terhadap total pendapatan kotor.

2. Cuaca ditarik dari titik pusat New York; hujan deras lokal di ujung borough tertentu tidak terekam.

3. Korelasi cuaca dengan harga sering bias oleh 'jam sibuk' (rush hour) sore hari yang kebetulan bersamaan dengan jadwal hujan.

Otomatisasi: Untuk diperbarui otomatis setiap bulan, tim data engineering dapat memasang cron scheduler yang memicu fungsi `pipeline_inkremental(bulan)`. Pipeline ini akan mengecek log bulanan, mengunduh file baru, dan melakukan append Parquet berpartisi tanpa mengganggu data lama.

4. Hasil Latihan Mandiri (Q.1 s.d. Q.5)

• Q.1 Memodifikasi unduh_aman: Menambahkan penghitungan selisih waktu `time.perf_counter()` sehingga fungsi mencetak kecepatan (MB/s). Terbukti saat dieksekusi 2x, panggilan kedua langsung membaca cache lokal (instan).

• Q.2 Menambahkan Aturan Validitas: Menambahkan 2 aturan: tip_amount >= 0 dan konsistensi tarif (fare + tip <= total). Aturan ini berhasil ditangkap dan dipetakan di tabel profil.

• Q.3 Join DOLocationID: Melakukan join pada lokasi turun (Drop-Off) dan menghasilkan 10 rute asal-tujuan terpadat, yang sangat esensial untuk analisis pergerakan komuter harian.

• Q.4 MinMaxScaler vs StandardScaler: MinMaxScaler memampatkan seluruh angka ke batas (0 hingga 1), sangat berbeda dari StandardScaler yang menormalkan sebaran ke pusat mean 0. MinMaxScaler wajib digunakan untuk algoritma berbasis jarak absolut, sedangkan StandardScaler lebih cocok untuk distribusi miring.

• Q.5 Pembuktian many_to_one: Saat tabel referensi Zona sengaja disuntik baris ganda, parameter `validate='many_to_one'` langsung melempar error (MergeError), sehingga mencegah replikasi jutaan baris transaksi palsu secara diam-diam.

5. Tugas Praktikum (R.1 s.d. R.4)

Tabel Komparatif (Tugas R.1 & R.2) membandingkan persentase kegagalan kualitas data antara Januari 2023 dan Juli 2023 yang diperoleh setelah menjalankan pipeline inkremental pada file Parquet Juli:

Aturan Validasi	Gagal Jan (%)	Gagal Jul (%)	Selisih (%)
Kelengkapan: passenger_count ada	2.339	2.927	0.588
Konsistensi: total >= fare	0.816	1.053	0.237
Validitas: total_amount > 0	0.840	1.075	0.235
Validitas: jarak 0-100 mil	1.498	1.717	0.219
Konsistensi: durasi 1-180 menit	1.186	1.311	0.125
Keunikan: baris tidak duplikat	0.000	0.000	0.000
Validitas: PULocationID dikenal	0.000	0.000	0.000

Analisis Komparatif: Aturan yang memburuk paling parah adalah ketiadaan 'passenger_count' (+0,588%). Kemungkinan besarnya disebabkan oleh musim liburan musim panas (Juli) yang mendatangkan lebih banyak penumpang turis luar kota yang memakai aplikasi e-hail pihak ketiga yang integrasi pencatatannya ke sistem TLC belum rapi.

Tugas R.3 (Sumber Keempat): Menambahkan API Hari Libur Nasional US (Nager.Date) untuk menambah kolom kategorikal 'is_libur', memperkuat prediksi analisis harga pada hari-hari non-kerja.

Tugas R.4 (Kamus Data): Dokumen `kamus_data.md` telah digenerasi untuk menjabarkan definisi lengkap, batas validasi, jenis data, serta metode imputasi untuk seluruh kolom yang tersedia di set terkurasi.

6. Pertanyaan Evaluasi (S.1 s.d. S.9)

S.1 Perbedaan ETL dan ELT, serta Alasan ELT Lebih Lazim di Big Data

ETL (Extract, Transform, Load) melakukan transformasi data sebelum disimpan ke dalam data warehouse, yang membutuhkan server komputasi terpisah dan lambat untuk data masif. ELT (Extract, Load, Transform) menyimpan data mentah langsung ke media penyimpanan modern, lalu memanfaatkan daya komputasi dari storage engine tersebut (BigQuery/Spark) untuk transformasi. ELT lazim di Big Data karena storage sekarang murah, skema data sering berubah, dan arsitektur ELT memungkinkan pemrosesan ulang data dari bentuk mentahnya kapan saja.

S.2 Tiga Risiko Akuisisi via API dan Cara Menanganinya

1. Rate Limits (HTTP 429): Ditangani dengan mekanisme 'exponential backoff' sebelum mencoba ulang.
2. Gangguan Server Sementara (HTTP 500, 502, 503): Ditangani dengan retry berjeda.
3. Perubahan Skema: Ditangani dengan validasi struktur JSON (pengecekan key) sebelum diurai.
Kode yang boleh dicoba ulang: 429, 500, 502, 503. Tidak boleh: 400, 401, 403, 404.

S.3 Perbedaan MCAR, MAR, dan MNAR serta Bahaya Pengisian MNAR

MCAR (Missing Completely At Random): Data hilang acak tanpa pola. MAR (Missing At Random): Hilangnya data bergantung observasi kolom lain. MNAR (Missing Not At Random): Kehilangan data bergantung pada nilai data itu sendiri (misal: supir mematikan argo untuk tarif yang sangat besar). Mengisi (imputasi) data MNAR sangat berbahaya karena menciptakan bias buatan yang menyembunyikan pola anomali sebenarnya dari analisis.

S.4 Kelemahan Z-Score pada Distribusi Miring

Metode Z-score mengasumsikan data terdistribusi normal (kurva lonceng). Pada data yang sangat miring ke kanan (seperti total tarif taksi), Z-score lambat bereaksi karena standar deviasinya membengkak secara tak wajar. Metode IQR (Interquartile Range) jauh lebih tangguh karena berbasis pembagian persentil statis yang tidak terpengaruh asimetri distribusi data ekor panjang.

S.5 Bahaya Kunci Ganda pada Join Many-to-One

Jika tabel referensi di sisi kanan memiliki kunci duplikat, proses join akan meledak (Cartesian/Row Explosion), sehingga menggandakan baris transaksi primer. Cara mencegahnya: (1) Eksekusi drop_duplicates di tabel referensi sebelum join. (2) Wajib pasang argumen validate='many_to_one' agar Pandas melempar AssertionError jika kunci referensi tidak unik.

S.6 Data Leakage dalam Scaling Fitur

Kebocoran data terjadi saat model machine learning tanpa sengaja 'mengintip' data uji karena metrik rata-rata scaling dihitung dari populasi penuh. Langkah yang benar: (1) Pisahkan data Train dan Test. (2) .fit() Scaler HANYA pada data Train. (3) .transform() diaplikasikan terpisah pada data Train dan data Test.

S.7 Pipeline yang Idempoten

Pipeline idempoten menjamin output akhirnya akan selalu sama (tidak ganda dan tidak terakumulasi) meskipun script dijalankan ribuan kali berulang-ulang. Dua teknis: (1) Menulis output file Parquet secara atomic ke partisi folder yang menimpa yang lama (mode overwrite). (2) Mengecek log flag/rekaman text keberadaan bulan untuk melewati proses unduhan yang mubazir.

S.8 Kerugian Mempartisi pada Kardinalitas Tinggi

Kardinalitas tinggi (misal mempartisi berdasarkan detik_transaksi atau LocationID=265 folder) menciptakan fenomena 'Small Files Problem'. Mesin akan menghabiskan jauh lebih banyak waktu membaca/mengurai jutaan metadata folder dibandingkan ukuran byte data itu sendiri, menyebabkan overhead server membengkak parah.

S.9 Empat Pemeriksaan Wajib Sebelum Web Scraping

(1) File robots.txt. (2) Regulasi Hak Cipta dan Ketentuan Layanan (ToS) platform. (3) Mekanisme laju request (Rate limiting) mandiri agar tidak membombardir DDoS. (4) Hukum privasi data pribadi (PII/GDPR). Kondisi mutlak penolakan: Jika area situs dilindungi password login yang ketat secara klausul menolak keberadaan bot ekstraktor.

Sumber Data & Etika Penggunaan Dataset

- TLC Yellow Taxi & Taxi Zone (Januari & Juli 2023): Merupakan data transaksi nyata taksi kuning New York yang diunduh dari repositori publik resmi NYC Taxi & Limousine Commission. Data ini bersifat terbuka (*open data*) dan telah di-anonimisasi (tidak mengandung *Personally Identifiable Information* / PII) sehingga legal dan etis untuk dianalisis secara bebas.
- Open-Meteo API (Historical Weather): Data arsip cuaca per jam yang disediakan secara publik dan gratis untuk penggunaan non-komersial tanpa memerlukan otentikasi (API Key).

- Nager.Date API (Public Holidays): Sumber data keempat yang berisi hari libur nasional Amerika Serikat, diakses melalui endpoint API publik terbuka.
- Basis Data SQLite Lokal: Tabel dimensi tarif yang disimulasikan dari file database internal lokal operasional.db untuk melatih pemuatan data secara bertahap (*chunking*).