LAPORAN PRAKTIKUM 5 BIG DATA
Pipeline Data Berita: dari Ingestion hingga MapReduce



Disusun Oleh:

Stanley Leonard Darmali/Kelas B

2311532021

Dosen Pengampu:

Afdhal Dinilhak

Ajeng Dwi Asti

Departemen Informatika

Fakultas Teknologi Informasi

Universitas Andalas

2026

Sumber Data & Etika Penggunaan Dataset

Dataset utama berupa judul berita detik.com periode 1 Januari–13 Juni 2020, dipublikasikan oleh Ibrahim pada repositori GitHub: https://github.com/ibamibrahim/dataset-judul-berita-indonesia (berkas detik_news_title.csv; URL unduh langsung: https://raw.githubusercontent.com/ibamibrahim/dataset-judul-berita-indonesia/master/detik_news_title.csv). Notebook mengunduh berkas tersebut saat dijalankan; keluaran menunjukkan ukuran 16,1 MB dan 91.017 baris. Tanggal eksekusi yang tampak pada keluaran crawling sitemap adalah 13 November 2026.

Data bersifat nyata, bukan sintetis. Portal lokal pada H-2/H-3/H-5 hanyalah simulasi layanan web yang menyajikan kembali dataset tersebut; bukan sumber berita baru. H-4 mengambil sampel 20 judul dari sitemap detik.com. Repositori dataset tidak mencantumkan lisensi. Judul berita tetap dilindungi hak cipta detikcom; penggunaan dibatasi untuk pembelajaran, sumber dikutip, dan data/isi berita tidak didistribusikan ulang. robots.txt, jeda, User-Agent, serta batas permintaan dihormati pada crawling sumber langsung.

1. Langkah Kerja (H-1 s.d. H-13)

H-1–H-2. Pemetaan pipeline dan persiapan data. Alur dibangun dari ingestion, quality/cleaning, storage, query, MapReduce, hingga serving. CSV berhasil dibaca dengan 91.017 baris dan empat kolom (date, url, title, category); portal lokal menyediakan 911 halaman, masing-masing hingga 100 judul.

H-3–H-4. Crawling HTML lokal dan sitemap berita. Pemeriksaan robots.txt mengizinkan /berita?hal=1 dan melarang /arsip-privat/. Parser HTML mengambil 300 judul dari tiga halaman lokal. Parser sitemap XML berhasil mengolah tiga contoh entri (ID 8729282, 8729280, 8729264). Pengambilan langsung menghasilkan 20 judul, tanpa judul kosong maupun URL duplikat; kategori terdiri dari news 7, inet 7, dan sport 6.

H-5. Channel ala Flume. Crawler bertindak sebagai source, queue.Queue berkapasitas 2.000 sebagai channel, dan sink menulis JSONL per 5.000 event. Sebanyak 91.017 event masuk dan seluruhnya ditulis ke 19 berkas; batas antrean terpenuhi. Ukuran lapisan mentah 20,7 MB dan waktu crawl 59,5 detik.

H-6. Quality, cleaning, dan Parquet. Dari 91.017 baris mentah, 78 gagal aturan panjang judul, 235 terindikasi duplikat, dan 5.640 URL tidak valid. Setelah normalisasi, penghapusan duplikat judul (menyimpan kemunculan pertama), dan penyaringan judul 3–30 kata, tersisa 90.818 baris (199 dibuang). URL rusak dikosongkan, bukan dijadikan alasan menghapus seluruh berita inet. Partisi kategori menghasilkan 9 file (8,4 MB); partition pruning kategori finance membaca 1 dari 9 file.

H-7. Query DuckDB dan dokumen. Agregasi kategori menghasilkan news 32.321; hot 16.290; finance 14.141; travel 6.453; inet 5.577; health 4.914; oto 4.375; food 4.314; dan sport 2.433. Judul yang memuat corona per bulan: Januari 385, Februari 1.077, Maret 6.994, April 4.913, Mei 2.934, dan Juni 943. Satu baris juga direpresentasikan sebagai dokumen JSON dengan atribut id, judul, kategori, tanggal, dan daftar kata.

H-8–H-9. Mini MapReduce dan word count. Kasus kantin menghasilkan nasi goreng 5, es teh 8, dan mie ayam 4; combiner mengurangi pasangan yang dikirim dari 12 menjadi 9. Word count berita memakai 9 file partisi sebagai input split, menghasilkan 825.601 pasangan dan 32.275 kata unik. Pemeriksaan terhadap Counter biasa bernilai True.

H-10–H-11. Combiner, paralelisme, dan data skew. Combiner menurunkan pasangan dari 825.601 menjadi 74.009 tanpa mengubah hasil. Dua proses tanpa combiner justru lebih lambat daripada satu proses pada eksekusi ini. Dengan empat reducer, beban tertinggi 29,17%; kata 'di' sendiri menyumbang 3,3% pasangan.

H-12–H-13. Hadoop Streaming dan serving. Pipeline mapper | sort | reducer menghasilkan 32.275 baris dan lima kata teratas yang sama dengan H-9; pemeriksaan kesetaraan bernilai True. H-13 menghitung kata teratas per kategori tanpa stopword, mengekspor 73.601 baris ke Parquet dan SQLite, serta memverifikasi tiga kata teratas kategori health.

2. Analisis Hasil

1) Paralelisme dan combiner (H-10). Pada pengujian ini, dua proses tanpa combiner membutuhkan 1,740 detik, lebih lama daripada satu proses (0,852 detik). Biaya pembuatan proses, koordinasi, dan pemindahan 825.601 pasangan melampaui pekerjaan mapper yang relatif ringan. Dengan combiner, volume pasangan turun menjadi 74.009 (sekitar 11,2 kali lebih sedikit); dua proses menjadi lebih cepat pada pengukuran ini (0,733 detik) dibanding satu proses (1,026 detik). Waktu bersifat bergantung lingkungan, sedangkan pengurangan pasangan merupakan temuan yang lebih stabil.

2) Data skew (H-11). Dengan empat reducer, reducer terberat menerima 29,17% pasangan dibanding bagian ideal 25%. Ketika jumlah reducer menjadi 64, beban terberat masih 4,28%, sedangkan bagian ideal hanya 1,56%. Menambah reducer tidak memecah satu key yang sama ke banyak reducer. Kata 'di' memiliki 27.390 kemunculan (3,3% dari seluruh pasangan) dan selalu diarahkan ke reducer yang sama. Combiner meratakan beban empat reducer menjadi 24,7–25,6% karena setiap mapper mengirim satu agregat per kata.

3) Stopword domain. Kata 'rp', 'ri', dan 'the' tetap muncul karena daftar stopword awal berisi kata fungsi umum, bukan seluruh token yang tidak relevan untuk setiap analisis. Ketiganya sebaiknya tidak otomatis dibuang: 'rp' dapat penting untuk topik ekonomi, 'ri' dapat merujuk pada Republik Indonesia, dan 'the' mungkin muncul pada nama/judul. Penambahan stopword harus mengikuti tujuan analisis dan dilakukan dengan mencatat dampaknya pada peringkat kata.

4) URL rusak kategori inet. Seluruh 5.577 baris inet yang tersisa memiliki URL tidak valid sehingga kolom id kosong. Jika URL dipakai sebagai kunci join, baris-baris tersebut tidak dapat dicocokkan secara andal dan penggunaan nilai '#' sebagai kunci berisiko menggabungkan banyak berita yang berbeda. Baris tetap dipertahankan karena judulnya sah untuk analisis teks; URL dikosongkan dan dokumen tanpa ID tidak diberi ID rekaan.

5) Pemilihan partisi kategori. Partisi kategori menghasilkan 9 file yang langsung menjadi 9 input split/mapper, sesuai kebutuhan analisis per kategori. Partisi kategori+bulan menghasilkan 54 file dengan ukuran total hampir sama, tetapi menambah jumlah file kecil tanpa manfaat yang sepadan dan memperbesar overhead pembacaan/metadata. Partisi bulan hanya menghasilkan 6 file dan kurang sesuai dengan pertanyaan yang membandingkan kategori.

6) Pengurutan sebelum reducer (H-12). Reducer membaca satu key pada satu waktu dan hanya menjumlahkan nilai selama key berurutan. Karena itu hasil mapper harus diurutkan berdasarkan kata sebelum masuk reducer. Tanpa sort/shuffle, key yang sama dapat muncul terpisah; reducer akan mencetak beberapa subtotal untuk key yang sama, bukan satu frekuensi global yang benar.

7) Sitemap dibanding membuka artikel. Sitemap menyediakan judul, tanggal, URL, dan kata kunci dalam struktur XML sehingga crawler tidak perlu mengunduh halaman artikel satu per satu. Ini mengurangi jumlah request dan beban server serta membuat parser tidak bergantung pada struktur HTML setiap artikel. Kekurangannya, isi sitemap terbatas pada metadata yang disediakan, dapat berbeda antarwaktu, dan tidak menggantikan pemeriksaan aturan robots.txt maupun batas permintaan.

3. Studi Kasus: Ringkasan Topik Berita Paruh Pertama 2020

Berdasarkan judul berita yang berhasil dibersihkan, perhatian terhadap corona meningkat tajam pada awal 2020 dan mencapai puncak pada Maret, dengan 6.994 judul. Jumlahnya turun menjadi 4.913 pada April dan 2.934 pada Mei. Data Juni mencatat 943 judul, tetapi hanya mencakup 13 hari pertama sehingga tidak dapat dibandingkan sebagai satu bulan penuh. Pada agregasi kata per kategori, news memiliki jumlah kemunculan kata corona terbesar, yaitu 7.539. Kategori health juga memperlihatkan fokus yang kuat pada isu kesehatan: corona muncul 2.590 kali, diikuti virus 1.040 kali dan pasien 471 kali. Perbedaan tema terlihat pada kategori food yang didominasi kata makanan, makan, foto, galeri, dan enak, sedangkan kategori oto menonjolkan mobil dan motor. Temuan ini menunjukkan bahwa isu corona menjadi tema lintas kategori, tetapi konteks pembahasannya berbeda menurut rubrik. Ada dua keterbatasan penting: dataset hanya berisi judul, bukan isi artikel, dan seluruh URL kategori inet tidak valid. Karena itu frekuensi kata tidak selalu mewakili isi atau nada pemberitaan secara utuh.

4. Tugas Mandiri: Inverted Index

Inverted index dibangun dengan mapper yang menghasilkan pasangan (kata, id dokumen), kemudian reducer menggabungkan ID unik untuk setiap kata. Stopword dikeluarkan agar indeks berfokus pada kata bermakna. Dari 90.818 dokumen bersih, 5.577 dokumen tidak memiliki ID asli dan dilewati; jumlah ini terutama berasal dari kategori inet. Keputusan ini mencegah pembuatan identitas dokumen palsu atau penggabungan dokumen berbeda ke ID yang sama.

Kata	Lima ID dokumen pertama	Keterangan
corona	4856495, 4856598, 4868317, 4868545, 4869163	Kata terkait isu utama
polisi	4842273, 4842280, 4842541, 4842612, 4843641	Kata terkait berita umum
bikin	4842061, 4842110, 4842430, 4842442, 4842488	Kata kerja yang muncul pada judul

Indeks memuat 31.018 kata unik setelah stopword dibuang. Hasil tersebut menunjukkan bahwa setiap kata dapat digunakan sebagai titik masuk untuk menemukan daftar dokumen yang memuatnya, tanpa memindai seluruh judul setiap kali pencarian dilakukan.

5. Kesimpulan

Praktikum berhasil membentuk pipeline dari crawling hingga penyajian hasil analisis. Pemeriksaan utama konsisten dengan acuan modul: 91.017 event masuk dan ditulis, 90.818 baris bersih, 9 partisi kategori, 825.601 pasangan word count, 32.275 kata unik, 74.009 pasangan setelah combiner, serta hasil Hadoop Streaming yang sama dengan H-9. Eksperimen menegaskan bahwa combiner efektif mengurangi data shuffle, paralelisme tidak selalu mempercepat data berukuran kecil, dan data skew dapat tetap terjadi walaupun jumlah reducer ditambah. Keputusan mempertahankan judul inet tetapi mengosongkan URL juga memperlihatkan pentingnya mempertimbangkan tujuan analisis sebelum menghapus data.

Daftar Pustaka

- Dean, J., & Ghemawat, S. (2004). MapReduce: Simplified Data Processing on Large Clusters. OSDI.

- White, T. (2015). Hadoop: The Definitive Guide (4th ed.). O'Reilly Media.
- Koster, M., dkk. (2022). Robots Exclusion Protocol (RFC 9309). IETF.
- Ibrahim, I. Indonesian News Title Dataset. https://github.com/ibamibrahim/dataset-judul-berita-indonesia (diakses 13 November 2026).

Apache Software Foundation. Hadoop Streaming 3.3.6. https://hadoop.apache.org/docs/r3.3.6/hadoop-streaming/HadoopStreaming.html